

**МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ
БЕЛАРУСЬ**

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ

СЕРГИЕНКО ЛЕВ ЭДУАРДОВИЧ

Отчет по
Лабораторная работа 9
Технология OpenMP: распараллеливание циклов

Преподаватель

Кондратьева О.М.

Задание 1

Текст программы

```
#include <iostream>
#include <omp.h>

int main()
{
    #pragma omp parallel
    {
        int tid = omp_get_thread_num();
        int nthreads = omp_get_num_threads();

        #pragma omp critical
        {
            std::cout << "Привет от потока "
                      << tid
                      << " из "
                      << nthreads
                      << std::endl;
        }
    }

    return 0;
}
```

Окно работы программы

```
lev@redmibook-15 /m/c/U/1/D/B/3/p/lab9 (main)> make run1
g++ -std=c++11 -fopenmp task1.cpp -o task1
./task1
Привет от потока 15 из 16
Привет от потока 9 из 16
Привет от потока 1 из 16
Привет от потока 3 из 16
Привет от потока 12 из 16
Привет от потока 2 из 16
Привет от потока 5 из 16
Привет от потока 4 из 16
Привет от потока 6 из 16
Привет от потока 7 из 16
Привет от потока 8 из 16
Привет от потока 10 из 16
Привет от потока 11 из 16
Привет от потока 13 из 16
Привет от потока 14 из 16
Привет от потока 0 из 16
```

Задание 2

Текст программы

```
#include <iostream>
#include <omp.h>

int main()
{
    const int N = 16;

    omp_set_num_threads(4);

    int count[32] = {0};

#pragma omp parallel for
    for (int i = 0; i < N; ++i)
    {
        int tid = omp_get_thread_num();
#pragma omp atomic
        ++count[tid];

#pragma omp critical
        {
            std::cout << "i=" << i
                        << " выполняет поток " << tid
                        << std::endl;
        }
    }

    std::cout << "\nИтераций по потокам:\n";
    for (int t = 0; t < omp_get_max_threads(); ++t)
    {
        std::cout << "Поток " << t << ": "
                  << count[t] << " итераций\n";
    }

    return 0;
}

#include <iostream>
#include <cmath>
#include <iomanip>
#include <omp.h>

int main()
{
    constexpr double PI = 3.141592653589;
```

```

const int sizes[] = {256, 1024, 4096};
const int threads[] = {1, 2, 4, 8, 16};

std::cout << " size | threads |   time (s)   \n";
std::cout << "-----+-----+-----\n";

for (int sz : sizes)
{
    for (int nt : threads)
    {
        omp_set_num_threads(nt);
        double *sinTable = new double[sz];

        double t0 = omp_get_wtime();
#pragma omp parallel for
        for (int n = 0; n < sz; ++n)
        {
            sinTable[n] = std::sin(2 * PI * n / sz);
        }
        double t1 = omp_get_wtime();

        std::cout
            << std::setw(5) << sz << " | "
            << std::setw(7) << nt << " | "
            << std::fixed
            << std::setprecision(6)
            << (t1 - t0) << "\n";

        delete[] sinTable;
    }
}

return 0;
}

```

Таблицы с результатами экспериментов

i=0 выполняет поток 0 i=8 выполняет поток 2	size	threads	time (s)
i=1 выполняет поток 0	1024	1	0.000032
i=2 выполняет поток 0	1024	2	0.000088
i=3 выполняет поток 0	1024	4	0.000110
i=12 выполняет поток 3	1024	8	0.000252
i=4 выполняет поток 1	1024	16	0.002590
i=13 выполняет поток 3	4096	1	0.000069
i=14 выполняет поток 3	4096	2	0.000030
i=15 выполняет поток 3	4096	4	0.000417
i=5 выполняет поток 1	4096	8	0.000171
i=6 выполняет поток 1	4096	16	0.003978
i=7 выполняет поток 1	16384	1	0.000323
i=9 выполняет поток 2	16384	2	0.000142
i=10 выполняет поток 2	16384	4	0.000434
i=11 выполняет поток 2	16384	8	0.000300
	16384	16	0.003918
Итераций по потокам:	32768	1	0.000910
Поток 0: 4 итераций	32768	2	0.000505
Поток 1: 4 итераций	32768	4	0.000769
Поток 2: 4 итераций	32768	8	0.000300
Поток 3: 4 итераций	32768	16	0.003623

Выводы

Распределение итераций

1. OpenMP по умолчанию использует статический режим, при котором диапазон $0 \dots N-1$ равномерно разбивается на блоки подряд идущих итераций размера $\lceil N/T \rceil$ (или $\lfloor N/T \rfloor$).
2. В эксперименте при $N=16$ и $T=4$ каждый из четырёх потоков получил ровно по 4 итерации.
3. Порядок строк в выводе ($i=8$ первым, потом $i=4$ и т. д.) определяется скоростью захода потоков в критическую секцию и не гарантирует упорядоченный вывод по i .

Влияние накладных расходов

Для маленького объёма работы ($size = 1024$) параллельный запуск во всех конфигурациях оказался медленнее однопоточного:

NT=1: 0.000032 с

NT=2: 0.000088 с

NT=4: 0.000110 с

NT=8: 0.000252 с

NT=16: 0.002590 с

Наладка потоков, синхронизация и перераспределение итераций «съедают» выигрыш при малом объёме, поэтому при $N \leq 4000$ даже два потока часто проигрывают одному.

Ускорение с ростом размера данных

1. При size = 4096 замечен выигрыш только для 2 потоков: 0.000030 с vs 0.000069 с (однопоточный).
2. При size = 16384 также лучшим оказался двухпоточный режим: 0.000142 с vs 0.000323 с.
3. Для самого большого теста (size = 32768) максимальное ускорение (0.000300 с) достигнуто при 8 потоках.

Задание 3

Выводы

В директиве

```
#pragma omp parallel for schedule(<kind>[,chunk_size])
```

параллельный for разбивается на «закрепленные» участки (chunks) по правилам выбранного алгоритма:

- **static**

Итерации делятся на почти равные блоки заранее: каждый поток получает одну (или несколько, если указан chunk_size) подряд идущих итераций. Низкие накладные расходы, но при неравномерных по времени итерациях, возможен дисбаланс.

Лучшее быстроедействие при **равномерно** нагруженных итерациях.

Плохо подходит, если время выполнения итераций сильно варьируется: одни потоки «зависают» на тяжёлых итерациях, другие простаивают.

- **dynamic**

Каждому потоку по очереди выдаётся блок (по умолчанию размер 1, либо `chunk_size`) из очереди до её опустения. При внезапно «тяжёлых» итерациях даёт лучший баланс, но с более высокими накладными расходами на выдачу блоков.

Хороший баланс даже при сильно разнородных итерациях, каждый поток берёт новую работу по факту готовности.

Высокие накладные расходы на синхронизацию и раздачу мелких задач, особенно при малом объёме работы.

- **guided**

Похож на `dynamic`, но размер блока уменьшается по мере «опустения» итераций: сначала большие участки ($\text{ceil}(N/\text{threads})$), потом всё меньше, пока не достигнет `chunk_size` (по умолчанию 1). Компромисс между балансом и накладными расходами.

Снижает общий `overhead` динамической схемы за счёт выдачи больших блоков в начале и уменьшения размера блока по ходу.

Идеален, когда изначально много работы, но последние несколько итераций могут быть тяжёлыми или лёгкими, сохраняет баланс без чрезмерных синхронизаций.

Задание 4

Текст программы

```
#include <iostream>
#include <omp.h>

int main()
{
    const int value = 2;
    const int n = 1000000;
    int counter = 0;

    #pragma omp parallel for
        for (int i = 0; i < n; ++i)
        {
            // закомментировать pragma, чтобы увидеть погрешность
            #pragma omp atomic
                counter += value;
        }

    std::cout << "counter = " << counter << std::endl;
    return 0;
}

#include <iostream>
#include <vector>
#include <random>
#include <limits>
#include <omp.h>
#include <iomanip>

int main()
{
    const int sizes[] = {1000000, 5000000, 10000000, 100000000};
    const int threads[] = {1, 2, 4, 8, 16};

    std::mt19937 gen(42);
    std::uniform_real_distribution<> dist(-1e6, 1e6);

    std::cout << " size | threads | time (s)\n";
    std::cout << "-----+-----+-----\n";

    for (int sz : sizes)
```



```

{
    std::vector<double> a(sz);
    for (int i = 0; i < sz; ++i)
        a[i] = dist(gen);

    for (int nt : threads)
    {
        omp_set_num_threads(nt);

        double t0 = omp_get_wtime();

        double global_min = std::numeric_limits<double>::infinity();
#pragma omp parallel for
        for (int i = 0; i < sz; ++i)
        {
            if (a[i] < global_min)
            {
#pragma omp critical
                {
                    if (a[i] < global_min)
                        global_min = a[i];
                }
            }
        }

        double t1 = omp_get_wtime();
        double dt = t1 - t0;

        std::cout
            << std::setw(7) << sz << " | "
            << std::setw(7) << nt << " | "
            << std::fixed << std::setprecision(6)
            << dt << "\n";
    }
}

return 0;
}

```

Таблицы с результатами экспериментов

Размерность задачи	Время выполнения последовательной, с	2 потока			4 потока			8 потока			16 потока		
		Время выполнения	Ускорение	Эффективность	Время выполнения	Ускорение	Эффективность	Время выполнения	Ускорение	Эффективность	Время выполнения	Ускорение	Эффективность
1 000 000	0,002112	0,001476	1,430894309	0,7154471545	0,000939	2,249201278	0,5623003195	0,000986	2,14198783	0,2677484787	0,004085	0,5170134639	0,03231334149
5 000 000	0,009512	0,005281	1,80117402	0,90058701	0,00352	2,702272727	0,6755681818	0,002585	3,679690522	0,4599613153	0,007334	1,296973002	0,08106081265
10 000 000	0,018817	0,010188	1,846976835	0,9234884177	0,005468	3,441294806	0,8603237015	0,007981	2,357724596	0,2947155745	0,005941	3,1673119	0,1979569938
100 000 000	0,188862	0,122711	1,539079626	0,7695398131	0,057357	3,292745436	0,8231863591	0,05123	3,686550849	0,4608188561	0,029462	6,410359107	0,4006474442

Задание 5

Тексты программ

```
#include <iostream>
#include <omp.h>

// Факториал с reduction
long long factorial_reduction(int number)
{
    long long fac = 1;
    #pragma omp parallel for reduction(* : fac)
    for (int n = 2; n <= number; ++n)
    {
        fac *= n;
    }
    return fac;
}

// Факториал с atomic
long long factorial_atomic(int number)
{
    long long fac = 1;
    #pragma omp parallel for
    for (int n = 2; n <= number; ++n)
    {
        #pragma omp atomic
        fac *= n;
    }
    return fac;
}

int main()
```

```

{
    const int Ns[] = {1000000, 10000000, 100000000};
    const int threads[] = {1, 2, 4, 8};

    std::cout << "Threads | reduction time (s) | atomic time (s)\n";
    for (int t : threads)
    {
        omp_set_num_threads(t);

        for (int N : Ns)
        {
            double t0 = omp_get_wtime();
            volatile long long r1 = factorial_reduction(N);
            double tr = omp_get_wtime() - t0;

            double t1 = omp_get_wtime();
            volatile long long r2 = factorial_atomic(N);
            double ta = omp_get_wtime() - t1;

            std::cout
                << t << "\t| "
                << tr << "\t\t| "
                << ta << "\n";
        }
        std::cout << "-----\n";
    }
    return 0;
}

```

////////////////////////////////////

```

#include <iostream>
#include <iomanip>
#include <cmath>
#include <omp.h>

double pi_serial(int N)
{
    double sum = 0.0;
    for (int n = 0; n < N; ++n)
        sum += ((n % 2 == 0 ? 1.0 : -1.0) / (2 * n + 1));
    return 4.0 * sum;
}

double pi_reduction(int N)
{
    double sum = 0.0;
    #pragma omp parallel for reduction(+ : sum)
    for (int n = 0; n < N; ++n)
        sum += ((n % 2 == 0 ? 1.0 : -1.0) / (2 * n + 1));
}

```

```

        return 4.0 * sum;
    }

double pi_atomic(int N)
{
    double sum = 0.0;
#pragma omp parallel for
    for (int n = 0; n < N; ++n)
    {
        double term = (n % 2 == 0 ? 1.0 : -1.0) / (2 * n + 1);
#pragma omp atomic
        sum += term;
    }
    return 4.0 * sum;
}

double pi_critical(int N)
{
    double sum = 0.0;
#pragma omp parallel for
    for (int n = 0; n < N; ++n)
    {
        double term = (n % 2 == 0 ? 1.0 : -1.0) / (2 * n + 1);
#pragma omp critical
        sum += term;
    }
    return 4.0 * sum;
}

int main()
{
    const int Ns[] = {1000000, 5000000, 10000000};
    const int threads[] = {2, 4, 8};
    const double PI_REF = std::acos(-1.0);

    std::cout << std::fixed << std::setprecision(6);
    std::cout << "Method      |      N | Threads |   Time(s) |   Error\n";
    std::cout << "-----\n";

    for (int N : Ns)
    {
        // serial
        double t0 = omp_get_wtime();
        double ps = pi_serial(N);
        double ts = omp_get_wtime() - t0;
        double es = std::fabs(ps - PI_REF);
        std::cout
            << std::setw(10) << "serial"
            << " | " << std::setw(7) << N
            << " | " << std::setw(7) << 1
            << " | " << std::setw(8) << ts

```

```

    << " | " << std::setw(8) << es
    << "\n";

for (int t : threads)
{
    omp_set_num_threads(t);

    // reduction
    t0 = omp_get_wtime();
    double pr = pi_reduction(N);
    double tr = omp_get_wtime() - t0;
    double er = std::fabs(pr - PI_REF);
    std::cout
        << std::setw(10) << "reduction"
        << " | " << std::setw(7) << N
        << " | " << std::setw(7) << t
        << " | " << std::setw(8) << tr
        << " | " << std::setw(8) << er
        << "\n";

    // atomic
    t0 = omp_get_wtime();
    double pa = pi_atomic(N);
    double ta = omp_get_wtime() - t0;
    double ea = std::fabs(pa - PI_REF);
    std::cout
        << std::setw(10) << "atomic"
        << " | " << std::setw(7) << N
        << " | " << std::setw(7) << t
        << " | " << std::setw(8) << ta
        << " | " << std::setw(8) << ea
        << "\n";

    // critical
    t0 = omp_get_wtime();
    double pc = pi_critical(N);
    double tc = omp_get_wtime() - t0;
    double ec = std::fabs(pc - PI_REF);
    std::cout
        << std::setw(10) << "critical"
        << " | " << std::setw(7) << N
        << " | " << std::setw(7) << t
        << " | " << std::setw(8) << tc
        << " | " << std::setw(8) << ec
        << "\n";
}
std::cout <<
"-----\n";
}

return 0;

```

```
}
```

```
////////////////////////////////////
```

```
#include <iostream>
#include <iomanip>
#include <vector>
#include <random>
#include <omp.h>
```

```
double dot_serial(const std::vector<double> &A, const std::vector<double> &B)
{
    double sum = 0.0;
    size_t M = A.size();
    for (size_t i = 0; i < M; ++i)
        sum += A[i] * B[i];
    return sum;
}
```

```
double dot_reduction(const std::vector<double> &A, const std::vector<double> &B)
{
    double sum = 0.0;
    size_t M = A.size();
#pragma omp parallel for reduction(+ : sum)
    for (size_t i = 0; i < M; ++i)
        sum += A[i] * B[i];
    return sum;
}
```

```
double dot_atomic(const std::vector<double> &A, const std::vector<double> &B)
{
    double sum = 0.0;
    size_t M = A.size();
#pragma omp parallel for
    for (size_t i = 0; i < M; ++i)
    {
#pragma omp atomic
        sum += A[i] * B[i];
    }
    return sum;
}
```

```
double dot_manual(const std::vector<double> &A, const std::vector<double> &B)
{
    double global_sum = 0.0;
    size_t M = A.size();
#pragma omp parallel
    {
```

```

    double local_sum = 0.0;
    int tid = omp_get_thread_num();
    int nthreads = omp_get_num_threads();
    size_t chunk = M / nthreads;
    size_t start = tid * chunk;
    size_t end = (tid == nthreads - 1 ? M : start + chunk);
    for (size_t i = start; i < end; ++i)
        local_sum += A[i] * B[i];
#pragma omp critical
    global_sum += local_sum;
}
return global_sum;
}

int main()
{
    const std::vector<size_t> Ms = {10000000, 50000000, 100000000};
    const int threads[] = {2, 4, 8};

    std::mt19937_64 rng(12345);
    std::uniform_real_distribution<double> dist(0.0, 1.0);

    std::cout << std::fixed << std::setprecision(6);
    std::cout << "Method      |          M | Threads |   Time(s)\n";
    std::cout << "-----\n";

    for (size_t M : Ms)
    {
        std::vector<double> A(M), B(M);
        for (size_t i = 0; i < M; ++i)
        {
            A[i] = dist(rng);
            B[i] = dist(rng);
        }

        // serial
        double t0 = omp_get_wtime();
        double ds = dot_serial(A, B);
        double ts = omp_get_wtime() - t0;
        std::cout
            << std::setw(10) << "serial"
            << " | " << std::setw(8) << M
            << " | " << std::setw(7) << 1
            << " | " << std::setw(8) << ts
            << "\n";

        for (int t : threads)
        {
            omp_set_num_threads(t);

            // reduction

```

```

t0 = omp_get_wtime();
double dr = dot_reduction(A, B);
double tr = omp_get_wtime() - t0;
std::cout
    << std::setw(10) << "reduction"
    << " | " << std::setw(8) << M
    << " | " << std::setw(7) << t
    << " | " << std::setw(8) << tr
    << "\n";

// atomic
t0 = omp_get_wtime();
double da = dot_atomic(A, B);
double ta = omp_get_wtime() - t0;
std::cout
    << std::setw(10) << "atomic"
    << " | " << std::setw(8) << M
    << " | " << std::setw(7) << t
    << " | " << std::setw(8) << ta
    << "\n";

// manual
t0 = omp_get_wtime();
double dm = dot_manual(A, B);
double tm = omp_get_wtime() - t0;
std::cout
    << std::setw(10) << "manual"
    << " | " << std::setw(8) << M
    << " | " << std::setw(7) << t
    << " | " << std::setw(8) << tm
    << "\n";
}
std::cout << "-----\n";
}

return 0;
}

```


Таблицы с результатами экспериментов

```
./bin/pg5.1
```

Threads		reduction time (s)		atomic time (s)
1		0.000761092		0.0026282
1		0.00757379		0.026305
1		0.0760641		0.262022

2		0.000785063		0.0099434
2		0.00377177		0.100218
2		0.037891		1.04466

4		0.000480069		0.0118216
4		0.00166797		0.119219
4		0.017469		1.15275

8		0.00050404		0.0119516
8		0.00151649		0.139889
8		0.0154056		1.33386

./bin/pg5.2

Method	N	Threads	Time(s)	Error
serial	1000000	1	0.002760	0.000001
reduction	1000000	2	0.002065	0.000001
atomic	1000000	2	0.022321	0.000001
critical	1000000	2	0.036777	0.000001
reduction	1000000	4	0.001286	0.000001
atomic	1000000	4	0.028065	0.000001
critical	1000000	4	0.071802	0.000001
reduction	1000000	8	0.000882	0.000001
atomic	1000000	8	0.032547	0.000001
critical	1000000	8	0.113480	0.000001
serial	5000000	1	0.016366	0.000000
reduction	5000000	2	0.007987	0.000000
atomic	5000000	2	0.103223	0.000000
critical	5000000	2	0.182515	0.000000
reduction	5000000	4	0.004310	0.000000
atomic	5000000	4	0.127488	0.000000
critical	5000000	4	0.336428	0.000000
reduction	5000000	8	0.002279	0.000000
atomic	5000000	8	0.156786	0.000000
critical	5000000	8	0.563674	0.000000
serial	10000000	1	0.030814	0.000000
reduction	10000000	2	0.015569	0.000000
atomic	10000000	2	0.204792	0.000000
critical	10000000	2	0.342318	0.000000
reduction	10000000	4	0.007661	0.000000
atomic	10000000	4	0.269933	0.000000
critical	10000000	4	0.620423	0.000000
reduction	10000000	8	0.004224	0.000000
atomic	10000000	8	0.379833	0.000000
critical	10000000	8	1.123597	0.000000

./bin/pg5.3

Method	M	Threads	Time(s)

serial	10000000	1	0.036372
reduction	10000000	2	0.019519
atomic	10000000	2	0.270992
manual	10000000	2	0.019110
reduction	10000000	4	0.012481
atomic	10000000	4	0.298865
manual	10000000	4	0.009630
reduction	10000000	8	0.009828
atomic	10000000	8	0.387534
manual	10000000	8	0.007160

serial	50000000	1	0.186254
reduction	50000000	2	0.098841
atomic	50000000	2	1.184447
manual	50000000	2	0.141307
reduction	50000000	4	0.090849
atomic	50000000	4	1.718968
manual	50000000	4	0.071969
reduction	50000000	8	0.048913
atomic	50000000	8	2.087962
manual	50000000	8	0.048511

serial	100000000	1	0.358412
reduction	100000000	2	0.196299
atomic	100000000	2	2.628974
manual	100000000	2	0.192449
reduction	100000000	4	0.146811
atomic	100000000	4	3.021313
manual	100000000	4	0.100716
reduction	100000000	8	0.088098
atomic	100000000	8	4.165211
manual	100000000	8	0.077104
