

Основные формулы

Число k определяется по формуле Стерджеса

$$k = 1 + [3,322 \lg n] = 1 + [\log_2 n], \quad \text{где } n - \text{объем выборки.}$$

Степенная средняя порядка p :

$$\bar{x}_p = \left(\frac{1}{n} \sum_{i=1}^n x_i^p \right)^{\frac{1}{p}}$$

$$\bar{x}_p = \left(\frac{1}{n} \sum_{i=1}^k m_i x_{(i)}^p \right)^{\frac{1}{p}} = \left(\sum_{i=1}^k w_i x_{(i)}^p \right)^{\frac{1}{p}}.$$

Порядок, p	Название	Формула вычисления для несгруппированного ряда	Формула вычисления для сгруппированного ряда (ВР)
-1	Средняя гармоническая	$\bar{x}_{-1} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$	$\bar{x}_{-1} = \frac{n}{\sum_{i=1}^k \frac{m_i}{x_{(i)}}}$
0	Средняя геометрическая	$\bar{x}_0 = \sqrt[n]{x_1 \dots x_n}$	$\bar{x}_0 = \sqrt[n]{x_1^{m_1} \dots x_k^{m_k}}, \quad n = \sum_{i=1}^k m_i$
1	Средняя арифметическая	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^k m_i x_{(i)}$
2	Средняя квадратическая	$\bar{x}_2 = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$	$\bar{x}_2 = \sqrt{\frac{1}{n} \sum_{i=1}^k m_i x_{(i)}^2}$
3	Средняя кубическая	$\bar{x}_3 = \sqrt[3]{\frac{1}{n} \sum_{i=1}^n x_i^3}$	$\bar{x}_3 = \sqrt[3]{\frac{1}{n} \sum_{i=1}^k m_i x_{(i)}^3}$

Медиана

ДВР	ИВР
$Me = \begin{cases} x_{l+1}^*, n = 2l + 1, \\ \frac{x_l^* + x_{l+1}^*}{2}, n = 2l. \end{cases}$	$Me = x_{Me} + h \frac{\frac{1}{2} - w_{Me-1}^c}{w_{Me}} \quad Me = x_{Me} + h \frac{\frac{n}{2} - m_{Me-1}^c}{m_{Me}},$ <p>где x_{Me} – нижняя граница медианного интервала.</p>

Свойство медианы:

$$\sum_{i=1}^n |x_i - Me| \leq \sum_{i=1}^n |x_i - L|, \quad \forall L \in \mathbb{R}.$$

Квантиль порядка p для ИВР:

$$Q_p = x_{Q_p} + h \frac{np - m_{Q_p-1}^c}{m_{Q_p}}, \quad Q_p = x_{Q_p} + h \frac{p - w_{Q_p-1}^c}{w_{Q_p}},$$

x_{Q_p} – нижняя граница квантильного интервала, порядка p ;

$$\text{Квартили: } q_1 = Q_{1/4} = x_{q_1} + h \frac{\frac{1}{4}n - m_{q_1-1}^c}{m_{q_1}}, \quad q_2 = Me, \quad q_3 = Q_{3/4} = x_{q_3} + h \frac{\frac{3}{4}n - m_{q_3-1}^c}{m_{q_3}}.$$

$$\text{Место квартили: } N_{q_1} = \frac{\sum_{i=1}^k m_i}{4}, \quad N_{q_2} = \frac{2 \sum_{i=1}^k m_i}{4}, \quad N_{q_3} = \frac{3 \sum_{i=1}^k m_i}{4}.$$

Мода

ДВР	ИВР
<p>Варианта с доминирующей частотой</p> <p>Применяют соглашения:</p> <ul style="list-style-type: none"> ❖ Если все варианты имеют одинаковую частоту, то говорят, что вариационный ряд не имеет моды. ❖ Если две или более соседние варианты имеют одинаковую доминирующую частоту, то мода равна средней арифметической этих вариантов. ❖ Если две (или более) несоседние варианты, имеют одинаковую доминирующую частоту, то говорят, что признак имеет две (или более) моды и называется <i>бимодальным (полимодальным)</i>. 	$Mo = x_{Mo} + h \frac{w_{Mo} - w_{Mo-1}}{2w_{Mo} - w_{Mo-1} - w_{Mo+1}},$ <p>где x_{Mo} – нижняя граница модального интервала.</p>

Предположим, что вся совокупность значений признака X разбита на j групп

$$\underbrace{x_1, \dots, x_{n_1}}_{(1)}, \underbrace{x_{n_1+1}, \dots, x_{n_1+n_2}}_{(2)}, \dots, \underbrace{x_{n_1+\dots+n_{j-1}+1}, \dots, x_n}_{(j)}$$

и для каждой группы вычисляется групповая средняя $\bar{x}^{(l)}, l = \overline{1, j}$.

Тогда средняя общая
$$\bar{x} = \frac{1}{n} \sum_{l=1}^j n_l \bar{x}^{(l)}.$$

Правило сложения дисперсий:

$$D_{\text{общ}} = \bar{D} + \bar{\delta}^2,$$

$$\bar{D} = \frac{D_1 n_1 + D_2 n_2 + \dots + D_j n_j}{n}; \quad \bar{\delta}^2 = \frac{n_1 (\bar{x}^{(1)} - \bar{x})^2 + \dots + n_j (\bar{x}^{(j)} - \bar{x})^2}{n}.$$

\bar{D} – средняя из внутригрупповых дисперсий; $\bar{\delta}^2$ – межгрупповая дисперсия.

$$\text{Коэффициент асимметрии: } A_s = \frac{\mu_{3,\bar{x}}}{\sigma^3} = r_3, \quad \text{где } \mu_{3,\bar{x}} = \frac{1}{n} \sum_{i=1}^k m_i (x_{(i)} - \bar{x})^3.$$

Если $A_s > 0$, то распределение скошено вправо, т.е. преобладают положительные отклонения от математического ожидания;

Если $A_s < 0$, то распределение скошено влево, т.е. преобладают отрицательные отклонения от математического ожидания;

Если $A_s = 0$, то распределение симметрично относительно математического ожидания.

Принято считать асимметрию при значениях:

$ A_s \leq 0,25$	малой,
$0,25 < A_s \leq 0,5$	умеренной,
$0,5 < A_s \leq 1,5$	большой,
$1,5 < A_s $	исключительно большой.

Иногда используют первый $A_s \approx \frac{\bar{x} - Mo}{\sigma}$ или второй $A_s \approx \frac{3(\bar{x} - Me)}{\sigma}$ приближенные коэффициенты асимметрии Пирсона.

Об остроте вершины кривой распределения судят по коэффициенту эксцесса:

$$E_x = r_4 - 3 = \frac{\mu_{4,\bar{x}}}{\sigma^4} - 3.$$

Если $E_x > 0$, то распределение имеет острый пик (по сравнению с нормальным распределением);

Если $E_x < 0$ (минимальное значение $E_x = -2$), то распределение имеет плосковершинную форму (по сравнению с нормальным распределением, для которого $E_x = 0$).

При $-0,5 < E_x < 3$ считают, что распределение приближается к нормальному.

В общем случае:

Условные средние: $\bar{y}_{x_i} = \frac{1}{m_{x_i}} \sum_{j=1}^l m_{ij} y_j$ и $\bar{x}_{y_j} = \frac{1}{m_{y_j}} \sum_{i=1}^k m_{ij} x_i$.

Общее среднее $\bar{y} = \frac{1}{n} \sum_{j=1}^l m_{y_j} y_j$; $\bar{x} = \frac{1}{n} \sum_{i=1}^k m_{x_i} x_i$;

В частном случае :

Общее среднее: $\bar{y} = \frac{1}{k} \sum_{j=1}^k y_j$; $\bar{x} = \frac{1}{k} \sum_{i=1}^k x_i$;

дисперсия: $\sigma_y^2 = \frac{1}{k} \sum_{j=1}^k (y_j - \bar{y})^2$; $\sigma_x^2 = \frac{1}{k} \sum_{i=1}^k (x_i - \bar{x})^2$,

ковариация: $\sigma_{xy} = \frac{1}{k} \sum_{i=1}^k (x_i - \bar{x})(y_i - \bar{y}) = \overline{xy} - \bar{x} \bar{y}.$

Коэффициент корреляции Пирсона: $r_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}.$

Оценка существенности линейного коэффициента корреляции при *большом* объеме выборки (свыше 50) проводится с использованием следующего

отношения для наблюдаемого значения критерия: $t_{\text{расч}} = \frac{r_{xy}}{\sigma_r},$ где $\sigma_r = \frac{1 - r_{xy}^2}{\sqrt{n - 1}} -$

среднеквадратическая ошибка линейного коэффициента корреляции, n – объем выборки. При *недостаточно большом* объеме выборки величину среднеквадратической ошибки коэффициента корреляции определяют по

формуле: $\sigma_r = \frac{\sqrt{1 - r_{xy}^2}}{\sqrt{n - 2}}.$

Коэффициент Фехнера: $K_\Phi = \frac{\Sigma C - \Sigma H}{\Sigma C + \Sigma H}.$

Коэффициент Спирмена: $r_c = 1 - \frac{6 \sum d_i^2}{n^3 - n},$ $d_i = R_{x_i} - R_{y_i}$ – разность рангов.

В случае присутствия связанных рангов

$$r_c = \frac{\frac{1}{6}(n^3 - n) - \sum_{i=1}^n d_i^2 - T_x - T_y}{\sqrt{\left\{\frac{1}{6}(n^3 - n) - 2T_x\right\} \left\{\frac{1}{6}(n^3 - n) - 2T_y\right\}}},$$

$$T_x = \frac{1}{12} \sum_{i=1}^p (t_i^3(x) - t_i(x)),$$

$$T_y = \frac{1}{12} \sum_{j=1}^q (t_j^3(y) - t_j(y)),$$

p – количество связанных рангов признака X;

$t_i(x)$ – количество значений признака X в i -ом связанном ранге;

q – количество связанных рангов признака Y;

$t_j(y)$ – количество значений признака Y в j -ом связанном ранге.

Коэффициент ассоциации $K_a = \frac{m_{11}m_{22} - m_{12}m_{21}}{\sqrt{m_{x_0}m_{x_1}m_{y_0}m_{y_1}}};$

Коэффициент контингенции $K_\kappa = \frac{m_{11}m_{22} - m_{12}m_{21}}{m_{11}m_{22} + m_{11}m_{22}}.$

Всегда $|K_a| \leq |K_\kappa|.$ Статистическая зависимость считается существенной, если $|K_\kappa| \geq 0,5, |K_a| \geq 0,3.$

Коэффициент корреляции Пирсона $\varphi = \frac{p_{xy} - p_x p_y}{\sqrt{p_x(1-p_x)p_y(1-p_y)}}$,

где p_x – доля выборочных значений признака x , равных 1;

p_y – доля выборочных значений признака y , равных 1;

p_{xy} – доля вариант (x_i, y_i) с единичными значениями у обоих признаков.

Каждый из двух признаков состоит более чем из двух групп:

Коэффициент взаимной сопряженности Пирсона $K_{\Pi} = \sqrt{\frac{\varphi^2}{1+\varphi^2}}$,

$$\varphi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{m_{ij}^2}{m_{x_i} m_{y_j}} - 1, \quad k, l - \text{число групп по двум признакам.}$$

Коэффициент взаимной сопряженности Чупрова $K_{\text{ч}} = \sqrt{\frac{\varphi^2}{\sqrt{(k-1)(l-1)}}}$.

Коэффициенты линейной модели регрессии: $a = \frac{\sigma_{xy}}{\sigma_x^2} = r_{xy} \frac{\sigma_y}{\sigma_x}, \quad b = \bar{y} - r_{xy} \frac{\sigma_y}{\sigma_x} \bar{x}$.

Дисперсия отклонения ε : $\sigma_{\varepsilon}^2 = \sigma_y^2(1 - r_{xy}^2)$.

Если $r_{xy} = \pm 1$ (т.е. $r_{xy}^2 = 1$), то $\sigma_{\varepsilon}^2 = 0$; модель является адекватной.

Если $r_{xy} = 0$, тогда σ_{ε}^2 совпадает с σ_y^2 , т.е. модель не является адекватной.

Коэффициент детерминации: $\eta_{y(x)}^2 = \frac{\overline{\delta^2}}{\sigma_y^2} = \frac{\sigma_y^2 - \sigma_{y/x}^2}{\sigma_y^2} = 1 - \frac{\sigma_{y/x}^2}{\sigma_y^2}$.

Чем ближе $\frac{\sigma_{y/x}^2}{\sigma_y^2}$ к нулю, тем модель адекватнее.

$$\eta_{y(x)} = \sqrt{1 - \frac{\sigma_{y/x}^2}{\sigma_y^2}}, \quad 0 \leq \eta_{y(x)} \leq 1 - \text{корреляционное отношение.}$$

В случае линейной зависимости: $\eta_{y(x)}^2 = r_{xy}^2$.

В остальных случаях $\eta_{y(x)}^2 \geq r_{xy}^2$.

Причем отклонение от линейности считается существенным, если $\eta_{y(x)}^2 - r_{xy}^2 \geq 0,1$. Если $\eta_{y(x)}^2 - r_{xy}^2 \leq 0,1$, то несущественным.

$$\begin{cases} a_1\sigma_{11} + a_2\sigma_{12} \dots + a_k\sigma_{1k} = \sigma_{1y} \\ \dots \\ a_1\sigma_{k1} + a_2\sigma_{k2} \dots + a_k\sigma_{kk} = \sigma_{ky} \end{cases} \quad a_0 = \bar{y} - a_1\bar{x}_1 - a_2\bar{x}_2 - \dots - a_k\bar{x}_k = \bar{y} - \sum_{j=1}^k a_j\bar{x}_j$$

$$\sigma_{ij} = \sigma_{x_i x_j}, \quad \sigma_{ii} = \sigma_{x_i}^2 = \sigma_i^2; \quad \sigma_{jy} = \sigma_{x_j y}.$$

$$a_1 = \frac{\sigma_2^2 \sigma_{1y} - \sigma_{12} \sigma_{2y}}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}, \quad a_2 = \frac{\sigma_1^2 \sigma_{2y} - \sigma_{12} \sigma_{1y}}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}.$$

Стандартизированные коэффициенты множественной регрессии $\beta_i = a_i \frac{\sigma_i}{\sigma_y}$.

$$\begin{cases} \beta_1 + \beta_2 r_{12} + \dots + \beta_k r_{1k} = r_{1y} \\ \dots \\ \beta_1 r_{k1} + \beta_2 r_{k2} + \dots + \beta_k = r_{ky} \end{cases}$$

Корреляционная матрица $R = \begin{pmatrix} 1 & r_{12} & \dots & r_{1k} \\ r_{21} & 1 & & r_{2k} \\ \dots & & & \dots \\ r_{k1} & r_{k2} & \dots & 1 \end{pmatrix}$

Коэффициент множественной детерминации: $r_y^2 = \frac{\bar{\delta}^2}{\sigma_y^2} = \sum_{i=1}^k \beta_i r_{iy} = -\Delta_{k+1} / \Delta_k$.

$$\Delta_k = \begin{vmatrix} 1 & r_{12} \dots & r_{1k-1} & r_{1k} \\ r_{21} & 1 & r_{2k-1} & r_{2k} \\ \dots & & & \dots \\ r_{k1} & r_{k2} & \dots & 1 \end{vmatrix}, \quad \Delta_{k+1} = \begin{vmatrix} 1 & r_{12} \dots & r_{1k} & r_{1y} \\ r_{21} & 1 & r_{2k} & r_{2y} \\ r_{k1} & r_{k2} \dots & 1 & r_{ky} \\ r_{1y} & r_{2y} \dots & r_{ky} & 0 \end{vmatrix}$$

Частный коэффициент детерминации:

$$r_{yx_j}^2 \setminus x_1 \dots x_{j-1} = \frac{r_y^2 - r_{y \setminus x_j}^2}{1 - r_{y \setminus x_j}^2}, \quad r_{yx_m}^2 \setminus x_1 \dots x_{m-1} x_{m+1} \dots x_k = \frac{r_y^2 - r_{y \setminus x_m}^2}{1 - r_{y \setminus x_m}^2}.$$

В случае k = 2: $r_y^2 = \frac{r_{1y}^2 + r_{2y}^2 - 2r_{1y}r_{2y}r_{12}}{1 - r_{12}^2}.$

$$r_{yx_1}^2 \setminus x_2 = \frac{r_y^2 - r_{y \setminus x_1}^2}{1 - r_{y \setminus x_1}^2} = / r_{y \setminus x_1}^2 = r_{2y}^2, \quad r_{y \setminus x_2}^2 = r_{1y}^2 / = \frac{(r_{1y} - r_{12}r_{2y})^2}{(1 - r_{12}^2)(1 - r_{2y}^2)}.$$

$$r_{yx_2}^2 \setminus x_1 = \frac{(r_{2y} - r_{12}r_{1y})^2}{(1 - r_{12}^2)(1 - r_{1y}^2)}.$$